Benemérita Universidad Autónoma de Puebla.

Facultad de Cs. Físico Matemáticas.

“Econometría I”

“Modelos de Regresión Lineal Múltiple.”

ALUMNOS:

- Huerta Barcenas Jessica.
- Moreno Sotero Alexa Esmeralda.
- Ramos Lopez Maritza Alondra.
- Serrano Hernandez Lenin.
- Gonzalez Galeana Sergio Alejandro.
- Peña Morales Carlos.

Primavera 2026.

1. Planteamiento del proyecto

Tema elegido: Determinantes del precio de las viviendas en el estado de Puebla.

- **Pregunta de investigación clara:**

¿Qué factores explican el precio de las viviendas en Puebla y cuál es la magnitud del impacto de variables como el tamaño, número de cuartos y ubicación?

- **Justificación económica:** El mercado inmobiliario refleja la interacción entre oferta y demanda de vivienda. Factores como el tamaño, ubicación y características estructurales afectan la disposición a pagar de los consumidores, lo que permite modelar el precio como función de estos.
- **Variable dependiente (Y) :** Precio de la vivienda
- **Variables explicativas (X) preliminares:**
  - β**1**=(Metros Cuadrados)
  - β**2**=(Cuartos)
  - β**3**=(Pisos)
  - β**4**=(Ubicación)
- **Hipótesis iniciales (signos esperados).**
  - **Superficie (X_1 - metros cuadrados):**
    - **Signo esperado:** Positivo (+).
    - **Sustento:** A mayor cantidad de metros cuadrados construidos, mayor es el costo de materiales y el valor del terreno, lo que incrementa el precio final.
  - **Baños/Recámaras (X_2 y X_3 - Cuartos/Pisos):**
    - **Signo esperado:** Positivo (+).
    - **Sustento:** Un mayor número de servicios internos aumenta la utilidad marginal de la vivienda para el comprador.
  - **Ubicación (X_4 - Latitud/Longitud):**
    - **Signo esperado:** Mixto/Variable.
    - **Sustento:** Se espera que el precio aumente conforme la ubicación se acerque a zonas de alta plusvalía como Angelópolis o Lomas de Cholula, o bien zonas cercanas al Centro Histórico de la ciudad de Puebla.

Datos.

- **Fuente de datos:** Base de datos de **Properati México** (2017), filtrada específicamente para el estado de Puebla.
- **Proceso de limpieza :** Se eliminaron observaciones con valores faltantes en variables clave y se filtraron outliers extremos en precio y superficie para evitar sesgos en la estimación. También, se construyó la variable de distancia al centro usando coordenadas
- **LINK**: https://www.kaggle.com/datasets/properati-data/properties.

- **LINK AL CÓDIGO**: https://colab.research.google.com/drive/1CuXYV6zCX-2zbsGhnJpm1CErWboRday_?usp=sharing

Nota: Se usó la base de datos para México 2017 para propiedades en venta

- **Descripción breve:** Para el desarrollo del modelo, se seleccionaron variables que capturan tanto la dimensión física de la vivienda como su entorno geográfico. A continuación, se detalla el diccionario de variables utilizadas tras el proceso de limpieza y transformación:
  - **Precio de la vivienda (precio_mxn):** Es la variable dependiente (Y).
  - **Superficie total (superficie_total):** Representa la extensión del terreno en metros cuadrados (m^2).
  - **Número de cuartos (cuartos):** Variable numérica discreta que indica la cantidad de habitaciones de la propiedad.
  - **Distancia al centro (distancia_centro_km):** Es una variable calculada mediante las coordenadas de latitud y longitud.

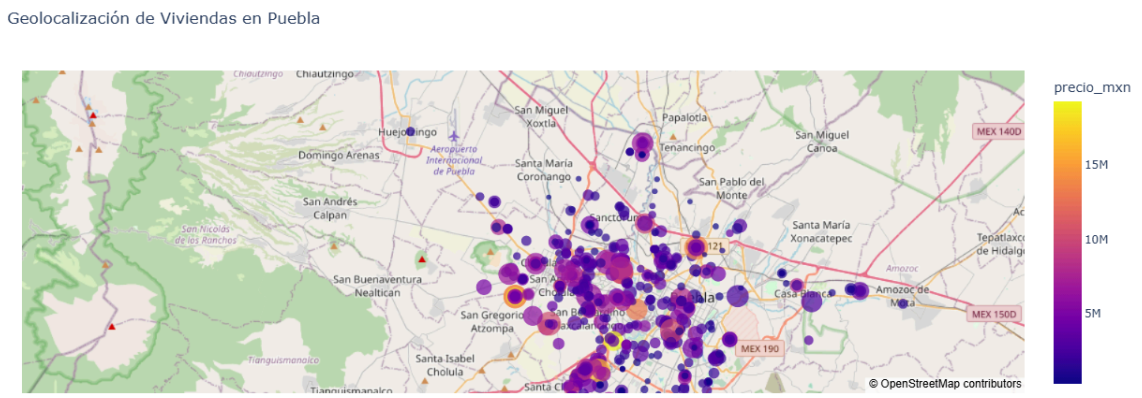

- **Diccionario de variables:**

VARIABLE	TIPO	UNIDAD	Descripción
precio_mxn	Continua	Pesos	Precio de la vivienda
superficie_total	Continua	Metros Cuadrados	Tamaño del inmueble
cuartos	Discreta	Número	Habitaciones
distancia_centro_km	Continua	Km	Distancia al centro de Puebla

Observaciones: Después de la limpieza realizada se obtuvieron 795 observaciones.

2. Exploración inicial (EDA).

a. Estadísticos descriptivos.

Estadísticos Descriptivos

	precio_mxn	superficie_total	superficie_cubierta	pisos	cuartos	lat	lon
count	7.950000e+02	795.000000	795.000000	795.000000	795.000000	795.000000	795.000000
mean	3.580235e+06	201.184906	240.851572	1.081761	1.189937	19.089338	-98.322035
std	2.454202e+06	145.988595	120.820581	0.332318	0.682933	0.516362	0.481566
min	3.153402e+05	38.000000	36.000000	1.000000	1.000000	18.897264	-102.552784
25%	2.034454e+06	124.500000	159.500000	1.000000	1.000000	18.993210	-98.322533
50%	3.231730e+06	165.000000	230.000000	1.000000	1.000000	19.044477	-98.276822
75%	4.267671e+06	210.000000	292.000000	1.000000	1.000000	19.059122	-98.234535
max	1.927645e+07	995.000000	850.000000	3.000000	5.000000	23.634501	-97.827278

La vivienda promedio en nuestra muestra tiene 201 m2. Observamos una alta desviación estándar en el precio, lo que justifica el uso de logaritmos para estabilizar la varianza y manejar los valores atípicos.

b. Distribuciones (Histogramas):

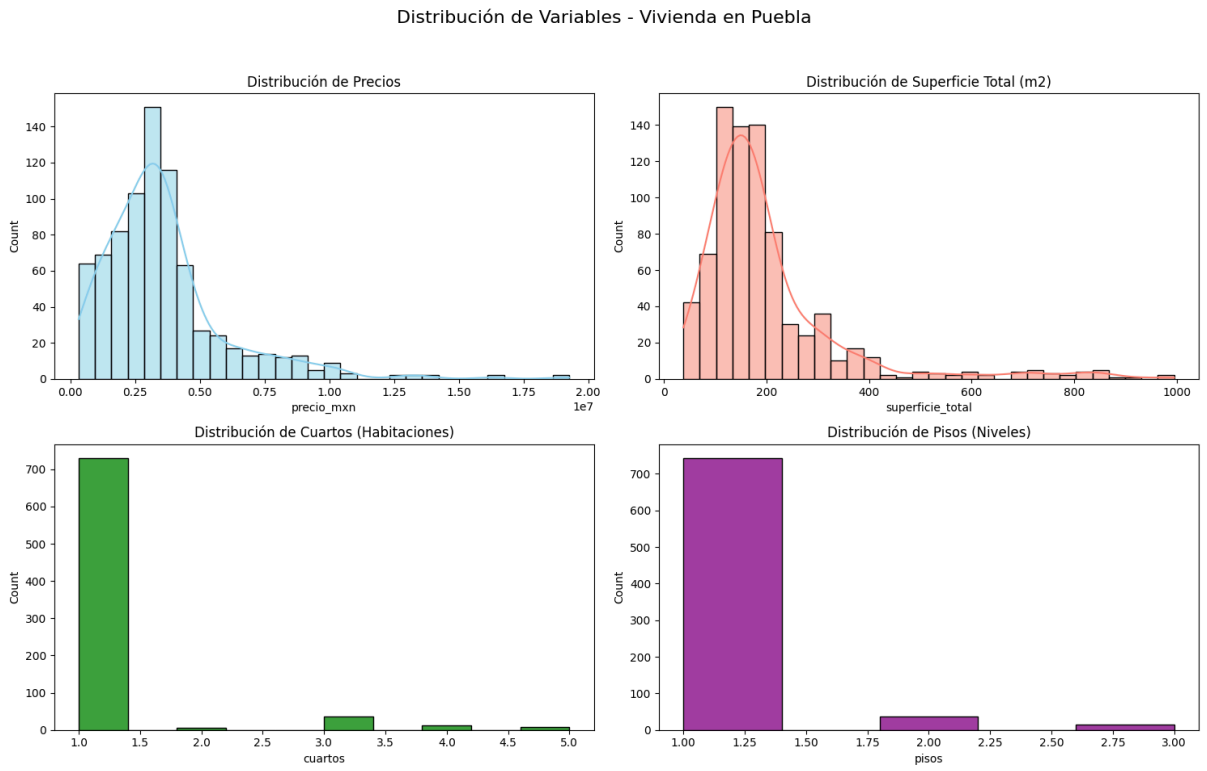

Los histogramas muestran que el precio tiene una distribución sesgada a la derecha, lo que justifica el uso de logaritmos para estabilizar la varianza.

c. Matriz de correlaciones:

Se observa una correlación positiva entre superficie y precio Es la correlación más fuerte del modelo. Esto indica que existe una relación positiva y moderadamente alta; a medida que aumenta la superficie total, el precio tiende a subir de forma clara. Es nuestro predictor principal.

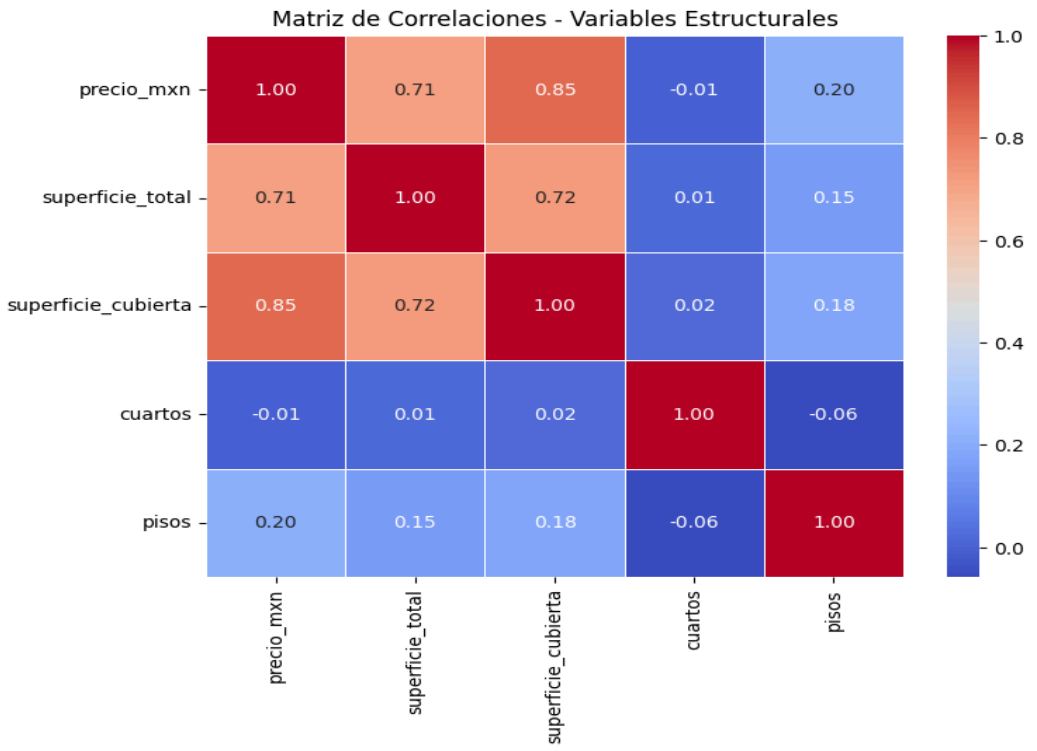

d. Valores faltantes y Outliers

	precio_mxn	superficie_total	superficie_cubierta	pisos	cuartos	lat	lon
638	4018046.42	174.0	312.0	1.0	1.0	18.964255	-98.289796
675	3356848.90	135.0	245.0	1.0	1.0	19.044477	-98.328011
693	1322395.03	90.0	90.0	1.0	1.0	19.066868	-98.282498
722	1780147.09	170.0	170.0	1.0	1.0	19.083184	-98.319795
1013	5391302.77	168.0	330.0	1.0	1.0	19.044477	-98.328011
...	...	...	...	...	...	...	...
128355	610336.01	67.0	63.0	1.0	1.0	18.994194	-98.249329
128357	2242985.31	163.0	163.0	1.0	1.0	19.067272	-98.312950
128406	4831828.07	200.0	260.0	1.0	1.0	19.044477	-98.328011
128425	1861525.23	92.0	185.0	1.0	1.0	18.989595	-98.203529
128521	1810523.38	120.0	140.0	1.0	3.0	18.984174	-98.190779

795 rows × 7 columns

Se identificaron valores extremos que podrían sesgar la estimación. Estos fueron tratados mediante cuartiles, lo que retiró 60 datos atípicos, quedando 735

observaciones, también se trabajó con datos faltantes en la base de datos para la variable “cuartos”, por lo que se relleno con 1s en dichos casos.

3. Modelo base estimado.

❖ Modelo teórico

$$\ln(Precio_i) = \beta_0 + \beta_1 \ln(Superficie_i) + \beta_2 Cuartos_i + \beta_3 Distancia_i + \varepsilon_i$$

Decidimos usar un Modelo Log-Log ya que, los precios de vivienda suelen tener distribuciones asimétricas (muchas casas baratas y pocas muy caras). El logaritmo ayuda a normalizar esta distribución.

❖ Reporte de Coeficientes (Modelo LOG)

```
                            OLS Regression Results
==============================================================================
Dep. Variable:         precio_mxn_log   R-squared:                       0.547
Model:                            OLS   Adj. R-squared:                  0.545
Method:                 Least Squares   F-statistic:                     294.4
Date:                Sun, 22 Mar 2026   Prob (F-statistic):          2.93e-125
Time:                        03:57:10   Log-Likelihood:                -416.47
No. Observations:                 735   AIC:                             840.9
Df Residuals:                     731   BIC:                             859.3
Df Model:                           3
Covariance Type:            nonrobust
==========================================================================================
                            coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                     9.9785      0.165     60.328      0.000       9.654      10.303
cuartos                  -0.0517      0.025     -2.055      0.040      -0.101      -0.002
superficie_total_log      0.9560      0.032     29.606      0.000       0.893       1.019
distancia_centro_km       0.0005      0.000      2.145      0.032    3.91e-05       0.001
==============================================================================
Omnibus:                       58.488   Durbin-Watson:                   1.730
Prob(Omnibus):                  0.000   Jarque-Bera (JB):               71.468
Skew:                          -0.764   Prob(JB):                     3.03e-16
Kurtosis:                       3.039   Cond. No.                         857.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

El modelo presenta un **R^2 de 0.547**, lo que indica que aproximadamente el **54.7%** de la variabilidad del precio es explicada por las variables incluidas.

❖ Interpretación de los Betas:

- **Superficie (log):** Es la más importante. Un aumento del **1% en la superficie** incrementa el precio en aproximadamente **0.956%**, es decir el precio sube casi en la misma proporción indicando una elasticidad positiva significativa.
- **Distancia al centro:** Por cada **1 km adicional** de distancia al centro, el precio aumenta en **0.0005 unidades**. El signo es **positivo**, pero esperábamos **negativo.** Esto sugiere que la variable no captura adecuadamente la estructura espacial del mercado inmobiliario.
- **Significancia:** Todas las variables tienen un P>|t| de 0.000, lo que significa que no son coincidencia; realmente afectan el precio.
- **Cuartos:** Un cuarto adicional reduce el precio en 0.0517 unidades. Aquí también hay un problema pues esperábamos un signo **positivo.**

Esto puede deberse a una multicolinealidad entre cuartos y superficie, o tal vez a un mal tratamiento de los datos, pues se tuvo que rellenar con 1s la base de datos.

- ➢ **Significancia estadística:** Todas las variables presentan valores p menores a 0.05, indicando que son estadísticamente significativas.

La superficie es el principal determinante del precio, mostrando una elasticidad cercana a la unidad. Sin embargo, los resultados para distancia al centro y número de cuartos presentan signos contrarios a lo esperado, lo que sugiere posibles problemas de especificación, variables omitidas o efectos estructurales del mercado inmobiliario en Puebla.

- ❖ **Diagnósticos mínimos.**
- ❖ **VIF (Multicolinealidad):** Los valores salieron casi en 1 (cuartos: 1.13, superficie: 1.00).
  - ➢ Nuestras variables no se estorban entre sí. Cada una aporta información diferente y nueva al modelo.

--- Diagnósticos para modelo_log ---

1. VIF para Multicolinealidad:

	variable	VIF
0	const	109.982225
1	cuartos	1.136232
2	superficie_total_log	1.003465
3	distancia_centro_km	1.133694

- ❖ **Breusch-Pagan (Heteroscedasticidad):** El p-value fue de 0.137.
  - ➢ Como es mayor a 0.05, pasamos la prueba. El modelo es homocedástico, o sea, el error es constante, lo cual es vital para que las predicciones sean buenas.
- ❖ **Ramsey RESET (Especificación):** Aquí el p-value nos dio casi 0, lo que indica: posibles variables omitidas o relaciones no lineales no capturadas
  - ➢ Aunque el modelo es bueno, hay relaciones (como zonas muy específicas de Puebla o acabados de lujo) que una línea recta no alcanza a captar. Es nuestra oportunidad de mejora para un modelo futuro.

4. Plan de Validación

Con el objetivo de mejorar la especificación del modelo y garantizar la validez de los resultados, se propone el siguiente plan de validación:

a) Reespecificación del modelo

Dado que el test de Ramsey RESET sugiere problemas de especificación, se propondrá:

- Incorporar **variables dummy de ubicación** para capturar diferencias entre zonas (centro, Angelópolis, periferia).
- Comparar el modelo actual con una versión alternativa que excluya variables redundantes.
- Se investigará si es pertinente añadir más variables que nos permitan explicar mejor el precio de las viviendas.
- Se evaluarán bases de datos alternativas que podrían ser más útiles.

b) Transformaciones funcionales

Se analizará la conveniencia de:

- Mantener la forma logarítmica (log-log) del modelo.
- Probar transformaciones adicionales en variables como la distancia al centro.
- Evaluar posibles relaciones no lineales.

c) Robustez del modelo

Para verificar la estabilidad de los resultados:

- Con los modelos alternativos a realizar, se correrán de nuevo las pruebas de diagnóstico (VIF, Breusch-Pagan).
- Uso de errores robustos (HC3) en caso de heterocedasticidad
- Se verificarán las técnicas de tratamiento de datos (como el añadir el 1 a los cuartos)
- Evaluación de influencia mediante distancia de Cook
- Comparación entre especificaciones mediante criterios AIC y BIC

Este plan permitirá identificar posibles deficiencias en la especificación del modelo y mejorar su capacidad explicativa y predictiva en la siguiente etapa del proyecto.

5. Cronograma

Estás actividades han sido trabajadas desde el 18 de Febrero a la fecha del día de hoy, 21 de Marzo, dónde se enlista el siguiente orden.

- 18 de Febrero: Definición del problema, hipótesis y las variables
- 23 de Febrero: Comienzo de recolección y limpieza de datos
- 24 de Febrero: Análisis Exploratorio (EDA)
- 2 de Marzo: Estimación del modelo base
- 4 de Marzo: Reunión de Equipo para revisar avances y hacer correcciones
- 9 de Marzo: Validación y diagnóstico del modelo
- 11 de Marzo: Análisis de Robustez
- 12 de Marzo: Reunión de equipo para correcciones necesarias
- 18 de Marzo: Redacción del documento final
- 21 de Marzo: Preparación de la presentación para exposición

A partir de la presente fecha y hasta las siguientes 3 semanas se trabajará el punto de Reespecificación y modelos alternativos del proyecto para hacer los ajustes necesarios. Las actividades se asignaron según los roles definidos para garantizar la correcta ejecución del proyecto.

6. Roles del equipo.

- Huerta Barcenas Jessica: Validación estadística y pruebas de robustez.
- Moreno Sotero Alexa Esmeralda: Redacción final, conclusiones y presentación.
- Ramos Lopez Maritza Alondra: Especificación econométrica y estimación del modelo.
- Serrano Hernandez Lenin: Análisis descriptivo y operatorio.
- Gonzalez Galeana Sergio Alejandro: Gestión y depuración de la base de datos.
- Peña Morales Carlos: Coordinador de Proyecto y Metodología.

7. Declaración del Uso de Inteligencia Artificial

En el desarrollo de este proyecto, se emplearon herramientas de Inteligencia Artificial Generativa (Gemini 1.5) para la resolución de errores estructurales en el entorno de Google Colab. La IA actuó como un consultor externo para contrastar los resultados obtenidos contra la teoría económica inmobiliaria. El 100% de los datos analizados provienen de la base original de Properati y todas las decisiones metodológicas (como el tratamiento de valores nulos con "1" y la exclusión de outliers) fueron supervisadas y ejecutadas por el equipo de investigación, utilizando la IA únicamente como un soporte de procesamiento y redacción.