



Determinantes del Precio de Vivienda en la Zona Metropolitana de Puebla

Modelo Hedónico de Precios con Datos de Corte Transversal

Equipo: Lobometricos.

Integrantes:

Huerta Barcenas Jessica.

Moreno Sotero Alexa Esmeralda.

Ramos López Maritza Alondra.

Serrano Hernández Lenin.

González Galeana Sergio Alejandro.

Econometría I

—Entrega Final—

Mayo 2026

1. Introducción

El mercado inmobiliario constituye uno de los sectores más relevantes de cualquier economía, tanto por su participación en el PIB como por su papel en la formación de riqueza de los hogares. En la Zona Metropolitana de Puebla (ZMP), el dinamismo urbano reciente ha generado una fuerte heterogeneidad en los precios de vivienda que merece ser estudiada con rigor econométrico.

El presente trabajo aplica el enfoque hedónico de precios (Rosen, 1974) para descomponer el precio de una propiedad en función de sus características estructurales y su localización espacial. Este informe presenta la Fase 2 del proyecto, comparando seis especificaciones alternativas con diagnóstico econométrico completo.

2. Pregunta de Investigación y Objetivos

2.1 Pregunta de investigación

¿Cuáles son los determinantes estructurales y espaciales del precio de vivienda en Puebla, y en qué magnitud cada característica contribuye al valor de mercado?

2.2 Objetivo general

Estimar un modelo hedónico de precios que identifique y cuantifique el efecto marginal de las características físicas, amenidades y localización sobre el precio, utilizando datos de corte transversal y MCO con corrección HC3.

2.3 Objetivos específicos

- Comparar seis especificaciones funcionales y seleccionar la más adecuada.
- Aplicar diagnóstico econométrico completo: VIF, Breusch-Pagan, White, RESET y Cook.
- Interpretar los coeficientes en términos económicos accionables.
- Evaluar la robustez ante la exclusión de observaciones influyentes.

3. Marco Teórico y Revisión de Literatura

El modelo hedónico de precios (Rosen, 1974) postula que un bien diferenciado puede caracterizarse como un conjunto de atributos, cada uno con un precio implícito. La literatura empírica ha documentado que la superficie construida es el principal determinante (Malpezzi, 2003), seguido por la localización (Can, 1992). La forma log-log es preferida (Halvorsen y Palmquist, 1980) porque captura rendimientos decrecientes.

4. Hipótesis

Hipótesis general: El precio está determinado significativamente por la superficie, amenidades y localización, con efectos diferenciados según el tipo de propiedad.


Variable	Signo esperado	Justificación económica
ln(m2)	+	Mayor superficie = mayor precio
Baños totales	+	Mayor funcionalidad y confort
Estacionamientos	+	Amenidad valorada en zonas urbanas
Antigüedad	- / 0	Depreciación física

Roof garden	+	Amenidad premium
Alberca	+	Amenidad de lujo
Zona Angelopolis	+	Zona de mayor plusvalía
m2 x casa	+	Metros cuadrados valen más en casas
m2 x antigüedad	-	Depreciación amplificada en inmuebles grandes

5. Datos

Se recopilaron 180 propiedades de Inmuebles24. Tras limpieza, la muestra final tiene 178 observaciones de corte transversal. A continuación, algunas gráficas para ver como se distribuyen los datos obtenidos.

Distribucion del Precio — Puebla



5.1 Fuente Y Descripción

Debido a la naturaleza de nuestro proyecto deberíamos de obtener nuestra base de datos de sitios que ofertan propiedades, así que después de una investigación determinamos utilizar la página “Inmuebles24” ya que cuenta con información que consideramos relevante. Para obtener los datos se realizó un scrapping en la página inmobiliaria, desafortunadamente al ejecutar el código desarrollado en Python la página bloqueo las direcciones IP y solo se pudieron obtener 180 datos.

Unidad de observación: Ciudad de Puebla y zonas conurbadas aledañas.

5.2 Diccionario de variables

Variable	Tipo	Descripción
precio_mxn	Continua	Precio de venta en MXN
m2	Continua	Superficie construida (m ²)
banos_tot	Continua	Baños completos + 0.5 x medios baños
estacionamientos	Discreta	Número de estacionamientos
antiguedad_anos	Continua	Antigüedad en años
roof_garden	Dummy	1 = tiene roof garden
alberca	Dummy	1 = tiene alberca
es_casa	Dummy	1 = casa, 0 = departamento
dist_zocalo_km	Continua	Distancia al Zócalo (km) (también esta su variante elevada al cuadrado)
zona_angelopolis	Dummy	Zona más cercana: Angelopolis
zona_la_paz	Dummy	Zona más cercana: La Paz
zona_las_animas	Dummy	Zona más cercana: Las Ánimas
zona_san_andres	Dummy	Zona más cercana: San Andrés

5.3 Tratamiento de Datos

a) Valores faltantes: Se identificaron dos variables con datos faltantes. La variable *estacionamientos* presento 11 valores nulos (6.1% de la muestra) y la variable *antiguedad_anos* presento 91 valores nulos (50.6%). En ambos casos, la naturaleza de la fuente de datos indica que un campo vacío en el portal Inmuebles24 significa que la propiedad no reporta esa característica: cero estacionamientos disponibles o una propiedad nueva/sin antigüedad reportada. Por esta razón, los valores faltantes se imputaron con cero, lo cual es consistente con la forma en que el portal organiza la información.

b) Detección y eliminación de outliers: Se identificaron dos tipos de errores de captura en la variable de superficie construida (m²). Primero, una observación reportaba m² = 0, lo cual es físicamente imposible y representa un error de captura en el portal; esta observación fue eliminada. Segundo, un departamento reportaba 9,134 m² de superficie construida, un valor claramente erróneo, que probablemente corresponde a la superficie del terreno total del complejo y no a la unidad individual, o una mala captura de los datos. Se aplicó un criterio conservador de eliminar departamentos con m² > 2,000, lo que eliminó esta única observación. En total se eliminaron 2 observaciones, pasando de 180 a 178.

c) Transformaciones aplicadas: Se realizaron las siguientes transformaciones sobre las variables originales:

Variables logarítmicas: Logaritmo natural del precio ($\ln_precio = \ln(precio_mxn)$) y logaritmo natural de la superficie ($\ln_m2 = \ln(m2)$). Estas transformaciones son justificadas porque los precios inmobiliarios se distribuyen log normal (asimetría positiva) y la transformación las simetriza, mejorando el cumplimiento de los supuestos de MCO. Además, permiten estimar elasticidades directamente.

Banos totales ($banos_tot = banos_completos + 0.5 \times medios_banos$): pondera los medios baños como la mitad de un baño completo, reflejando su menor funcionalidad.

Dummy tipo de propiedad: $es_casa = 1$ si la propiedad es casa, 0 si es departamento. Permite capturar efectos diferenciados entre los dos submercados.

Distancia al Zócalo: calculada mediante la fórmula de Haversine a partir de las coordenadas de cada propiedad y las coordenadas del Zócalo de Puebla (19.0437, -98.1978). Se elevo al cuadrado para capturar rendimientos decrecientes de la cercanía.

Logaritmo de distancia: $\ln_dist_zocalo = \ln(dist_zocalo_km + 0.1)$. Se agrega 0.1 para evitar $\log(0)$. Esta transformación captura efectos no-lineales adicionales a la cercanía al zócalo, ya que entre más cerca se encuentre el precio debería subir más rápidamente, pero este efecto va disminuyendo mientras la propiedad se aleja del zócalo.

Asignación de zona de plusvalía: cada propiedad fue asignada a la zona de plusvalía mas cercana (Angelópolis, San Andrés, La Paz, Las Animas o San Manuel) usando distancias Haversine a los centroides de cada zona. Las zonas de Cholula y Lomas VW fueron excluidas del modelo porque ninguna observación fue asignada a ellas (todas las propiedades de la muestra están más cerca de otras zonas).

Variables de interacción para modelos alternativos: Se construyeron las siguientes interacciones para explorar en los diferentes modelos: $inter_m2_alberca = \ln_m2 \times alberca$ (elasticidad diferenciada si hay alberca), $inter_m2_antiguedad = \ln_m2 \times antiguedad_anos$ (depreciación amplificada en inmuebles más grandes), $inter_rg_alberca = roof_garden \times alberca$ (efecto adicional si tiene ambas amenidades), $inter_m2_casa = m2 \times es_casa$ (valor diferencial del m2 en casas vs. deptos.), $inter_banos_m2 = banos_tot \times \ln_m2$ (efecto de la densidad de baños relativa al tamaño). Estas interacciones fueron evaluadas en las especificaciones M3 y M4, mientras que M2, M5 y M6 utilizaron solo variables base sin interacciones

6. Metodología

6.1 Modelo Base

El modelo base es una regresión lineal múltiple estimada por MCO con errores estándar robustos HC3 en todas las especificaciones para garantizar inferencia valida ante heteroscedasticidad, en este modelo base se usó todas las variables de la base de datos (m2, estacionamiento, recamaras, baños, estacionamiento, antigüedad, roof garden, alberca, es casa, distancia al zócalo al cuadrado, así como las variables dummy de zona de plusvalía).

6.2 Modelos Alternativos

Regresión lineal múltiple por MCO con errores HC3. Se estimaron seis modelos:

Modelo	Forma funcional	Características
M1	Lineal-Lineal	P en nivel, m2 en nivel, todas las variables + zonas
M2	Log-Log	$\ln(P) \sim \ln(m2) +$ variables base + zonas
M3	Log-Log + interacc.	M2 + $m2 \times casa$, $m2 \times antig$, $baños \times m2$, $\ln(dist)$
M4	Log-Log + todas	M3 + $m2 \times alberca$, $roof \times alberca$

M5	Log-Log simple	Solo ln(m2), estac. y zonas
M6	Log-Log espacial	Solo ln(m2), dist. y zonas

6.3 Modelo Seleccionado

El modelo final seleccionado es M3. Los modelos fueron comparados mediante:

- R2 ajustado
- AIC
- BIC
- RESET
- Breusch-Pagan
- White

El modelo seleccionado fue el log-log con interacciones, ya que presentó el mejor balance entre ajuste, interpretación económica y desempeño en pruebas de diagnóstico.

```
ln(Pi) = B0 + B1*ln(m2) + B2*banos + B3*estac + B4*roof + B5*alberca + B6*casa +
        B7*(m2 x casa) + B8*(m2 x antig) + B9*(banos x ln_m2) + B10*ln(dist_zoc) +
        B11-14*zonas + ei
```

6.4 Supuestos y estrategia de identificación

La estrategia combina: (a) la distancia continua al Zocalo al cuadrado, que captura el gradiente de accesibilidad con rendimientos decrecientes, y (b) dummies de zona que controlan por amenidades no observables compartidas dentro de cada micro-mercado. Primero se estimó un modelo lineal, por Mínimos Cuadrados Ordinarios (MCO) con matriz de varianzas robustas HC3 para corregir la heterocedasticidad detectada. Luego varios modelos log-log, y después agregamos interacciones y variables de localización. Los modelos usan errores robustos HC3 para corregir heteroscedasticidad.

7. Resultados

7.1 Comparación de modelos

Modelo	R ²	R ² -adj	AIC	BIC
M1	0.7161	0.6936	5827.43	5871.98
M2	0.8066	0.7913	135.7	180.25
M3	0.882	0.8711	51.69	102.59
M4	0.8856	0.8719	54.2	117.84
M5	0.7808	0.7731	144	166.27

M6	0.719	0.7091	188.23	210.5
----	-------	--------	--------	-------

Test F (M2 vs M3): $F = 34.5411$, $p = 0$. Interacciones mejoran significativamente.

Test F (M3 vs M4): $F = 1.6484$, $p = 0.1804$. Se prefiere M3 por parsimonia.

7.2 Coeficientes del Modelo 3

Variable	Coef.	Err. Est.	t	p-valor
const	10.3237	0.4124	25.035	0***
ln_m2	0.8932	0.0862	10.365	0***
banos_tot	0.2443	0.1576	1.551	0.121
estacionamientos	0.0654	0.0275	2.374	0.0176**
roof_garden	0.063	0.0472	1.333	0.1825
alberca	0.1916	0.1162	1.649	0.0991*
es_casa	-0.1491	0.0944	-1.58	0.1142
inter_m2_casa	0.0007	0.0006	1.349	0.1772
inter_m2_antiguedad	-0.0009	0.0006	-1.578	0.1146
inter_banos_m2	-0.0455	0.0249	-1.825	0.068*
ln_dist_zocalo	-0.1246	0.0895	-1.392	0.1638
dist_zocalo_km2	0.0004	0.001	0.403	0.6873
zona_angelopolis	0.3361	0.0606	5.543	0***
zona_la_paz	0.2617	0.0671	3.9	0.0001***
zona_las_animas	0.2432	0.1144	2.127	0.0334**
zona_san_andres	0.5358	0.0931	5.755	0***

$R^2 = 0.882$, $R^2\text{-adj} = 0.8711$, $n = 178$. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

7.3 Interpretación económica

Se omitieron las variables estadísticamente no significativas.

ln_m2 (0.8932): Un aumento de 1% en los metros cuadrados incrementa aproximadamente el precio en 0.89%, manteniendo constantes las demás variables. Es el coeficiente más importante del modelo y confirma que el tamaño es uno de los principales determinantes del valor inmobiliario.

Estacionamientos (0.0654): Un estacionamiento adicional incrementa el precio aproximadamente en 6.5%, manteniendo constantes las demás características. El resultado es estadísticamente significativo y consistente con la idea de que el estacionamiento tiene valor económico en zonas urbanas.

alberca (0.1916): Las propiedades con alberca presentan precios aproximadamente 19.2% mayores respecto a propiedades equivalentes sin alberca. El efecto es significativo al 10%, lo que sugiere evidencia moderada de una prima asociada a esta amenidad.

inter_banos_m2 (-0.0455): Esta interacción sugiere que el efecto positivo de los baños disminuye conforme aumenta el tamaño del inmueble. Puede interpretarse como rendimientos

marginales decrecientes: en propiedades muy grandes, agregar baños adicionales aporta relativamente menos valor porcentual. El resultado es marginalmente significativo al 10%.

Elasticidad precio-superficie (0.8932): Un incremento del 1% en m² se asocia con +0.8932% en precio. Rendimientos decrecientes, consistente con la teoría hedónica.

Zona San Andrés (+53.58%), Angelopolis (+39.9%) y La Paz (+29.9%) presentan primas significativas respecto a San Manuel(categoría base). La más grande del modelo es la Zona San Andrés, indicando una fuerte valorización de esta zona.

Interacción m2 x antigüedad (-0.0009): El signo negativo confirma que la depreciación se amplifica con la superficie: inmuebles más grandes y antiguos pierden más valor, consistente con mayores costos de mantenimiento.

Las interacciones sugieren que el valor marginal de ciertas características depende del contexto del inmueble.

8. Validación y Diagnóstico

8.1 Multicolinealidad (VIF)

Variable	VIF	Diagnóstico
ln_m2	8	Moderado (5-10)
banos_tot	9.38	Moderado (5-10)
estacionamientos	2.41	OK (<5)
roof_garden	1.2	OK (<5)
alberca	1.14	OK (<5)
es_casa	2.79	OK (<5)
inter_m2_casa	6.47	Moderado (5-10)
inter_m2_antigüedad	1.94	OK (<5)
inter_banos_m2	13.12	ALTO (>10)
ln_dist_zocalo	4.36	OK (<5)
dist_zocalo_km2	3.12	OK (<5)
zona_angelopolis	1.84	OK (<5)
zona_la_paz	1.8	OK (<5)
zona_las_animas	1.7	OK (<5)
zona_san_andres	1.49	OK (<5)

8.2 Heteroscedasticidad

Prueba	LM	p-valor	Conclusión
Breusch-Pagan	36.5703	0.0015	Heteroscedasticidad
White	136.0225	0.1228	No se rechaza H0

Corrección: errores HC3 aplicados en todos los modelos.

8.3 Especificación (RESET)

Modelo	F	p-valor	Conclusión
M3	3.6901	0.0271	Espec. correcta
M4	2.5109	0.0845	Espec. correcta

8.4 Influencia (Cook) y Robustez

Se identificaron 15 observaciones influyentes (umbral $4/n = 0.0225$), se concluye que el modelo es sensible a Outliers.

Variable	M3 (n=178)	M3 filt. (n=163)	Delta %	Estabilidad
ln_m2	0.8932	0.9741	9.1%	Estable
banos_tot	0.2443	0.1352	-44.7%	Cambio grande
estacionamientos	0.0654	0.0639	-2.3%	Estable
roof_garden	0.063	0.0759	20.5%	Cambio grande
alberca	0.1916	0.1787	-6.7%	Estable
es_casa	-0.1491	-0.1226	17.8%	Estable
inter_m2_casa	0.0007	0.0005	-32.5%	Cambio grande
inter_m2_antiguedad	-0.0009	-0.0011	-16.1%	Estable
inter_banos_m2	-0.0455	-0.03	33.9%	Cambio grande
ln_dist_zocalo	-0.1246	-0.1836	-47.4%	Cambio grande

Variables estables: ln_m2, estacionamientos, alberca, es_casa, inter_m2_antiguedad. Variables con cambios grandes: banos_tot, roof_garden, inter_m2_casa, inter_banos_m2, ln_dist_zocalo.

9. Conclusiones

Tras comparar varios modelos econométricos, se concluyó que el modelo log-log con algunas interacciones (Modelo 3) ofrece el mejor equilibrio entre ajuste e interpretación, ya que logra representar de manera más realista el comportamiento del mercado inmobiliario. Además, aunque se detectó heterocedasticidad en los modelos, el uso de errores robustos permitió obtener inferencias confiables. En general, el análisis muestra que tanto las características físicas de la propiedad como la ubicación influyen significativamente en el precio final de las viviendas en Puebla, obteniendo como puntos relevantes los que siguen:

- Elasticidad precio-superficie de 0.8932, altamente significativa.
- San Andrés (+70.9%), Angelópolis (+39.9%) y La Paz (+29.9%) presentan primas significativas.
- M3 (R^2 -adj = 0.8711) ofrece el mejor balance ajuste-parsimonia.
- Heteroscedasticidad presente en todos los modelos, corregida con HC3.

Limitaciones

- Muestra pequeña ($n = 178$), precios de lista, sin variables no observables.

10. Referencias

- Can, A. (1992). Specification and estimation of hedonic housing price models. *Regional Science and Urban Economics*, 22(3), 453–474.
- Halvorsen, R., y Palmquist, R. (1980). The interpretation of dummy variables in semilogarithmic equations. *American Economic Review*, 70(3), 474–475.
- MacKinnon, J. G., y White, H. (1985). Some heteroskedasticity-consistent covariance matrix estimators. *Journal of Econometrics*, 29(3), 305–325.
- Malpezzi, S. (2003). Hedonic pricing models: A selective and applied review. En *Housing Economics and Public Policy*. Blackwell.
- Rosen, S. (1974). Hedonic prices and implicit markets. *Journal of Political Economy*, 82(1), 34–55.
- Sobрино, J. (2014). Housing prices and submarkets in Mexico City. *Estudios Económicos*, 29(1), 57–84.